

① 统一队列下的批组队与错峰调度：系统模型与执行语义

《共享 KV 统一队列下的 Batch 效率与错峰调度形式化分析》2026-09-13 · §2 / §4–§7 · 单位：秒、GB、GB/s

系统模型



存储纪律 | FCFS 按需分配 (式 1)

$b_j(t) = \min\{q_j(t), [B(t) - \sum_{h < j} b_h(t)]^+\}$ 工作守恒 $\sum b_j = \min(B, \sum q_j)$
先满足在先流的申请速率，剩余带宽顺延给后续流——非公平共享；申请率 q 由统一引擎协议生成，不是优化变量

逐层执行递推 (式 3–6)

$A_{\beta,1} = u_\beta$; $A_{\beta,\ell+1} = C_{\beta\ell}$ (计算开始即提交下层读取)
 $C_{\beta\ell} = \max(R_{\beta\ell}, Z_{\beta,\ell-1})$; $Z_{\beta\ell} = C_{\beta\ell} + c_{\beta\ell}$; $F_i = Z_{\beta,L}$
同实例活动区间互斥 (含读取等待) : $[u_\beta, Z_{\beta,L}] \cap [u_\gamma, Z_{\gamma,L}] = \emptyset$ ——只禁计算重叠不够

TTFT 三段分解 (式 7)

$T_i = F_i - a_i = (u_\beta - a_i) + K_\beta + S_\beta$ = 中央等待 + 整批同步计算 + I/O STALL
 K 为整批同步计算时间，不可按成员数均摊；读取藏于计算窗口内不计 STALL——批计算收益与带宽需求此消彼长

批工作量三元组 (§2) : $N_\beta = \sum u_i$ 线性层 | $A_\beta = \sum [u_i h_i + u_i(u_i+1)/2]$ attention 配对 | $V_{\beta\ell}$ KV 字节——批大小与总 token 均非单一维度

② 完整优化问题 G1–G6：封闭的输入、决策与约束

文档 A · §5–§6 · G1–G4 封闭 → 实际速率 b 与完成时间 F 均为决策 σ 的诱导结果，求解器不得自选有利的 b

G1 输入 | G2 决策变量 (式 G1–G2)

G1 输入 = $(I, m, L, \{a_i, d_i, T_i^0, (v_{i\ell})\}, \text{批目录}, \{c_{\beta\ell}\}, B(t), q_{\max}, \text{服务规则})$

$\sigma = (P, w, u) : P$ 批划分 ; $w: P \rightarrow \{1, \dots, m\}$ 实例指派 ; $u: P \rightarrow$ 领取时刻 ($\geq t_0$) ——完成向量 $F_i = \Phi_i(P, w, u)$

批目录 = 容量合法批子集 · 画像 c 冻结不变 · 服务规则 = FCFS 粒度 / 申请协议 / 同刻顺序——三者固定后求解器不得自选有利的实际速率 b

G3 约束系统 | G4 存储规则 (封闭)

- ① 每请求恰执行一次 $\sum_{\beta \in P} 1[i \in \beta] = 1$
- ② 到达与容量 $u_\beta \geq \max_{i \in \beta} a_i$; 批合法 (人数 / token / 内存)
- ③ 首层与逐层释放 $A_{\beta,1} = u_\beta$; $A_{\beta,\ell+1} = C_{\beta\ell}$
- ④ 读取完成 $R_{\beta\ell} = \inf \{ t \geq A_{\beta\ell} : \int_A b_{\beta\ell} = V_{\beta\ell} \}$
- ⑤ 计算依赖 $C_{\beta\ell} = \max(R_{\beta\ell}, Z_{\beta,\ell-1})$; $Z_{\beta\ell} = C_{\beta\ell} + c_{\beta\ell}$
- ⑥ 实例互斥 $w_\beta = w_\gamma \rightarrow [u_\beta, Z_{\beta,L}) \cap [u_\gamma, Z_{\gamma,L}) = \emptyset$
- ⑦ 批内共同完成 $F_i = Z_{\beta,L}$ (完整批成员绑定至末层)

G4 $b_j(t) = \min\{q_j(t), [B(t) - \sum_{h < j} b_h(t)]^+\}$ (式 1, 全局提交序)
+ q 协议: 首层申请 $q_{\max}$; 下一层 $\min(q_{\max}, V/c)$; 窗口结束仍未读完 → 升至 $q_{\max}$ 、保留原 FCFS 序号

G5 四条独立优化线 $\inf_{\sigma \text{ 满足 G2–G4}} J_\theta(\Phi(\sigma)), \theta \in \{M, S, T, R\}$

- J_M** $\min \max_i F_i - t_0$
全部完成时间 M
- J_S** $\min (1/n) \sum 1[F_i > d_i]$
SLO 失败数 (满足率 = $1 - J$)
- J_T** $\min (1/n) \sum (F_i - a_i)$
平均 TTFT (含中央等待)
- J_R** $\min (1/n) \sum (F_i - a_i) / T_i^0$
平均归一化 TTFT (短请求权重更大)

G6 解释指标 $K = \sum \sum c$; $S = \sum (Z_{\beta L} - u_\beta - K)$; $I = mM - K - S$ $U_{\text{comp}} = K/(mM)$;
 $U_{\text{stor}} = \sum v / \int B$ —— K 随批形可变 → $\max U \neq \min M$

目标间关系 : 四线独立求解, 一般无共同最优; 运营组合可用词典序 (先满足率、后归一化) 或 ε -约束 ($A_{\text{SLO}} \geq \eta$ 下 $\min$ 平均 TTFT) ; 任意加权和引入业务权重且不保证覆盖离散 Pareto 解

③ 逐目标 NP-hard：归约构造与证明要点

文档 A · §9 · 归约子问题：batch=1 · v=0 · L=1 · a=0；复杂性针对全输入族的通用精确算法（ $P \neq NP$ 假设下）

归约框架：关闭四个开关（§9.1）

batch 上限 = 1 → 批目录仅含 singleton，请求不可拆分

v = 0（无命中） → 读取消失，FCFS 自动满足

L = 1 → 层间依赖与 lookahead 消失

a = 0（同时到达） → 无须等待未来请求

剩余问题：把计算时长 $c = p_i$ 的不可分请求装入 m 台实例 —— 经典非抢占调度

论证方向：若存在解全部 Case A 输入的精确算法 → 该子问题多项式可解 → 3-PARTITION 多项式可解，矛盾。增加存储竞争不会让该算法逃过此特例

J_M 与 J_S ：3-PARTITION 构造（§9.2–9.3）

构造 3-PARTITION 实例： $3m$ 个整数 $D/4 < p_i < D/2$ ， $\sum p_i = mD$ ；映射为单请求批（ $c = p_i$ ）、 m 同构实例、 $a=0$ 、 $v=0$ 、 $L=1$ ；问： $M \leq D$ ？

□ 若可分 m 组、每组和恰为 D → 每实例依次领取一组 → 每台恰忙 D → $M = D$

→ 若 $M \leq D$ ： $\sum c = mD$ 迫使每实例恰好忙碌 D ； $p_i \in (D/4, D/2)$ 迫使每实例恰含 3 个请求 → 得到三划分

结论 $M \leq D$ 当且仅当存在三划分 → J_M 强 NP-hard；令所有 $d_i \equiv D$ ：满足率 100% 当且仅当 $M \leq D$ → J_S 同样强 NP-hard（不依赖丢弃请求）

直觉 (4,5,6; 4,5,6) 可装两盒各 15；同总量 30 的 (4,4,4,6,6,6) 最优 $M = 16$ —— 总量相等不保证可分装； $m=2$ 时退化为 PARTITION（普通 NP-hard）

J_T ：总流水时间（§9.4）

单实例 · batch=1 · v=0 · 异到达： $\sum T_i = \sum F_i - \sum a_i$ ， $\sum a_i$ 为常数 → 等价于 $1|r_i|\sum C_i$ ，强 NP-hard [Lenstra · Rinnooy Kan · Brucker 1977, Th.5]。同时到达 + 单机时 SPT 多项式 → 硬度依赖「释放时间」

J_R ：总 stretch（§9.5）

$T_i^0 = p_i$ （singleton 参考）→ $\sum T_i / T_i^0 = \sum (F_i - a_i) / p_i$ ，即 $1|r_i|\sum S_i$ ，判定版 NP-complete [Legrand · Su · Vivien 2008, Th.4，PARTITION 归约]。权重 $1/p_i$ 结构特定——不可由「加权即难」推出；不升级强 NP-hard

硬度边界：① NP-hard $\neq$ 小规模不可精确求解（页④给出有限空间证书）；② $\neq$ 无多项式特例（同时到达单机 SPT、子问题 LPT 近似比 $4/3 - 1/3m$ ）；③ 一般 m 的强 NP-hard 与 $m=2$ 的普通 NP-hard 不可互相外推；④ 在线难度另叠一层——未来到达与带宽未知，非抢占「先启长批」可被随后紧急短请求反转，离线全知参考仅衡量优化空间，非可部署 Oracle

④ 可解性：最优证书、动作全局代价与目标冲突实证

文档 A · §7.2–7.3 / §8.3 / §10 · 四请求算例为假设参数闭式解（总读 20 GB · 计算 12 NPU·s，事件积分可逐位复核）

离线·小规模精确：分支定界与证书（§10）

求解空间 冻结候选批目录 + 启动网格 δ + 同刻顺序 $\rightarrow$ 分支定界；必须含「再等一格」WAIT 空动作，否则不搜索主动错峰

证书 $LB \leq J^* \leq UB$ ，相对 gap = $(UB-LB)/LB$ ； $LB=0$ 时报绝对差；SLO 用区间 $[A_{LB}, A_{UB}]$

下界 B1 $e_i = \max(t, a_i) + \min_{\beta \in i} \sum_{\ell} c_{\beta \ell}$ （忽略 I/O-机器伙伴，乐观放宽） $\rightarrow LB_M = \max e_i$ ；S/T/R 同构

下界 B2 计算分摊 $k_i = \min \Sigma c / |\beta|$ ；存储下界 h_B ： $J_B \geq V_{tot}$ ；计算下界 K/m —— 与 B1 取 max 不相加（I/O 与计算可重叠）

子问题保证 LPT： $M \leq (4/3 - 1/3m) \cdot M^*$ （Graham 1969）——进入共享存储/可变组批后假设消失，SPT/EDF/互补无通用近似比

在线·动作的全局代价与滚动 MPC（§7.2–7.3, §11）

严格价值 $Q^*_j(X_t, \alpha) = \inf_{\sigma \in S(X_t, \alpha)} J(\sigma)$ （离线条件价值，与原问题同难） $\rightarrow$ 可实现：同后续策略 π + 同情景重放，预测完成记 F_i^α （动作分支）与 F_i^0 （基准）， $\Delta_i = F_i^\alpha - F_i^0$

$$\Delta(J_M) = \max_i F_i^\alpha - \max_i F_i^0 \quad (\text{不可用 } \max \Delta_i \text{ 替代})$$

$$\Delta(J_S) = (1/n) \sum [1(F_i^\alpha > d_i) - 1(F_i^0 > d_i)] \quad (\text{阶跃：过期 } 20s \rightarrow 15s \text{ 无收益，} 10.1s \rightarrow 10s \text{ 才挽救})$$

$$\Delta(J_T) = (1/n) \sum \Delta_i \quad ; \quad \Delta(J_R) = (1/n) \sum \Delta_i / T_i^0$$

要求：每个增量必须计入被波及请求（他实例·队列·排位变化）并重新模拟；MPC：事件触发 $\rightarrow$ 候选批 $\rightarrow$ 联合动作 + 有界等待 $\rightarrow$ 按 Δ 排序 $\rightarrow$ 只落实首动作

同一请求集（2 长 + 2 短·两实例·两层·B = 4 GB/s）：四个可行计划的完整对照（§8.3）

计划（领取决策）	M (s)	平均 TTFT (s)	平均归一化	SLO 满足率	STALL (NPU·s)
P1 SS 批先领取	10.75	7.875	2.186	100%	3.75
P2 LL 批先领取	10.25	8.375	2.469	100%	4.75
P3 两个混合批	8.717	8.244	2.656	50%	4.49
P4 SS 先领、LL 延迟 0.5s	11.0	7.75	2.100	100%	3.00

判读：P3 的 M 最小却 SLO 最差（短请求全超期）；P2 缩短 M 却恶化两种均值；P4 STALL 最少、均值最优，M 却最大 $\rightarrow$ 四目标无共同最优，不能按 STALL / 利用率 / 是否混批等单一局部指标选计划。四个计划未穷尽候选与启动时刻，不宣称全局最优

⑤ 问题形式化的变化（I）：决策空间与服务规则

《共享 KV 多 ASU 多 Path 下的组批错峰与带宽协同调度设计》2026-09-17 · §1 / §4-§5 · 相对 Case A 的形式化增量

维度	Case A · 统一队列（G1-G4）	Case B · 多 ASU 多 Path（式 5-15）
存储资源	单一共享带宽 B(t)；全局 FCFS 按需分配	D 盘 × 40 GB/s 独立带宽域；每盘 256 条 Path FIFO 队列
放置与粒度	批×层聚合读取流；v_il 为固定输入	hashID 一致性哈希定唯一盘（不可迁移）；Block 级读/写 I/O，manifest 固定
决策变量	$\sigma_A = (P, w, u)$ ：批 · 实例 · 时刻	$\sigma_B = (B, \{(w_\beta, s_\beta)\}, \{p_j\}, \{\theta_d(t)\})$ ：新增逐 I/O 选路、盘级带宽规则两层
服务规则	式(1) 全局序 FCFS + q 申请协议	每 Path 仅队头获服务；组/请求带宽由 θ_d 给出（现状 B0 见下）
请求类别	无类别结构	$\chi_i = (1[h > 80K], 1[u > 512]) \rightarrow SS/LS/SL/LL$ ；Path 组 96/96/32/32，类别进入 I/O 权利
写回与完成	纯读； $F = Z_\beta L$ 三段分解	新增写回 V^W 与暂存池背压； $F = Z_\beta L$ 保持，另报 $F^{persist}$ ；四态 K+S+O+I

联合计划（式 9）

$$\sigma = [B, \{[w_\beta, s_\beta]\}, \{p_j\}, \{\theta_d(t)\}]$$

批划分 | 实例·启动 | 逐 I/O 选路 | 盘级带宽规则
新增两层均为决策变量；基线 $\theta=B0$ ；求解器不能选违反分配器 / FIFO / 容量的任意 b

现状服务规则 B0 的形式化（式 6-7）：两条结构性性质

式(6) $b_{d,p} = r_{c(p)} + (40 - \sum_{p' \in A_d} r_{c(p')}) / n_d$ （仅活跃 Path；非活动为 0） 式(7)： $B_{dc}^{act} = a_{dc} r_c + (a_{dc} / \sum_e a_{de})(40 - \sum_e a_{de} r_e)$

性质 1（守恒） $n_d > 0$ 时 $\sum_p b_{d,p} = 40$ —— 工作守恒；20/12/4/4 是基础份额而非组上限

性质 2（外部性） 组份额 $\propto$ 活跃 Path 数：SS 组 1→2 条 → 20.04→26.72 GB/s，LS 同期 19.96→13.28 → 多开 Path = 改变权利分配而非创造带宽

⑥ 问题形式化的变化（II）：执行依赖、守恒与可行性判据

文档 B · §4.6 / §5–§6 · 全局 FCFS 与「总字节 ÷ 总带宽」估计在此模型中结构化失效

执行依赖与守恒（式 5 · 10 · 11 · 12）

需求张量（式 5） $V^{R/W}_{\beta\ell dc} = \sum_{i \in \beta; \chi=c} \sum_{disk(k)=d} v_{ik\ell}$ 批×层×盘×类；大前缀天然跨盘，热前缀成热点；同 hash 相关性在所有层保留

I/O 守恒（式 10） $dx_j/dt = -z_j \cdot b_{d(j),p(j)}$, $x_j(A_j) = v_j$ 仅队头 $z=1$ 获服务；层就绪 $R_{\beta\ell}$ = 该层全部读 I/O 完成时刻的最大值（不可用平均估计）

层递推 + 写缓冲（式 11） $C_{\beta\ell} = \max(R_{\beta\ell}, Z_{\beta,\ell-1}, E_{\beta\ell})$ E：写暂存预留最早时刻（Case A 无此项）；写 I/O 于 Z 释放、读 lookahead 至多提前一层；不可为未执行批预建 I/O

设备四态守恒（式 12） $K + S + O + I = mH$ O = 写暂存 / 控制背压（新增态）；首 token 后写仍占 buffer 与后端带宽，但不占 NPU 实例 → M 与 M_persist 必须分列

实例互斥扩展 $[s_\beta, F_\beta)$ 不重叠的区间含读取等待、计算与暂存背压——比 Case A 的活动区间定义更宽

可行性判据（式 14–15）

瞬时 $\sum_p b_{d,p} \leq B_d(t) \leq 40$ ；仅已释放 · 已入队 · 队头的 I/O 获服务；已入队不可撤回 / 越队 / 迁移

窗口 $\rho_d(\Delta) = \text{窗口需求} / \int B_d$ ； $\rho > 1 \rightarrow$ 必失守； $\rho \leq 1$ 不保证无 STALL（I/O 晚释放或排在前缀之后）

长期必要 $\lambda \cdot E[V_d^R + V_d^W] < 40$ （逐盘）且 $\lambda \cdot E[K] < m$ —— 必要而非充分（FIFO 前缀 · 端点 · 暂存仍可限制）

散度 $\text{skew}(V) = \max_d V_d / \text{均值}$ ；哈希均匀 ≠ 访问均匀——热点由共享前缀的相关性决定，不能靠环再平衡消除

多盘尾部：总量条件的失效（§8.4，解析算例）

两盘各 40 GB/s：同层读向量 (8, 0) GB → 完成下界 **0.2 s**；(4, 4) GB → **0.1 s**；总量同为 8 GB，8/80 = 0.1 仅后者可达

→ $\sum_d V_d \leq 40 \cdot D \cdot (\tau - s)$ 只是必要条件；放置由哈希固定，不可为凑并行把块改放他盘；组批与并发筛选应比较盘需求向量，而非请求类别标签

结构性结论： Case B 的可行性是向量约束——带宽域 × 队列前缀 × 消费窗口三维耦合；任何标量化（总量 / 平均带宽 / 队列条数）在结构上不足以判定可行性与代价

⑦ 复杂性继承、新决策层的外部性与可解性

文档 B · §7.2 / §9–§10 · 新增自由度不降低难度，且使动作价值不可分解——联合重放是问题要求的评价方式

复杂性继承 (§9)

嵌入子问题 $\text{batch}=1 \cdot v^R = v^W = 0 \cdot L=1 \cdot a=0 \rightarrow$ 哈希 / Path / 带宽决策全部失效，剩余纯机器调度

→ **页③全部归约原样成立**： J_M / J_S 强 NP-hard； J_T / J_R NP-hard——新增存储自由度只增加约束维度，不缩小子问题

$X \in \{2, 4, 8\}$ 不妨碍归约 固定 $X=2, P=2 \rightarrow$ 实例数 $m = D$ (盘数) 随输入增长；或以长度 D_0 的填充作业把机器数补至 X 整数倍；一般 m 强 NP-hard， $m=2$ 仅 PARTITION (普通 NP-hard)

推论 「适用于所有输入的精确多项式算法」在 Case B 同样被排除；若强制每请求正读写、固定 $P=1/D=1$ 等子类，须另行证明——硬度不自动外推

新决策层的外部性 (§7.2)

选 Path p 活跃集 A_d 改变 $\rightarrow$ 式(6) 重算整盘全部 $b_{d,p}$ ——自身收益与他流损失耦合

调组权重 / 开 Path 延迟其他组的关键块；对非瓶颈盘加速不改变本层就绪 $\max_j R_j$ (白费带宽)

Deadline $\neq$ 消费时刻 SLO 是首 token 截止；消费时刻只预告 STALL——不可用 EDF 一类单规则替代四目标重放

写回耦合 写与读共享 40 GB/s；暂存池水位反馈进入层依赖 ($E_{\beta\ell}$)，读优可造成写背压

→ **动作价值不可分解相加**：若干互相影响的单点报价之和 $\neq$ 联合后果；联合重放是问题结构的要求，不是算法偏好

证书与信息边界 (§10, §11.2)

三档有限空间证书 E-S 仅调度 $\rightarrow$ E-SP 增选路 $\rightarrow$ E-SPB 增带宽目录 (逐档扩大)；证书只对声明的目录 / 网格成立，目录最优 $\neq$ 连续 $b_{d,p}$ 最优

四目标下界 (式 16) 乐观完成 $e_i \rightarrow LB_M = \max e_i - t_0$ 等；盘下界 $t + V_d^{R,rem}/40$ (异步写不计入 M ； $F_{persist}$ 口径并入写)；计算下界 K_{rem}^{lb}/m ——各下界取 $\max$

观测边界 普通策略仅见观测投影 O_t (磁盘组服务量 / 活跃数 / Path 未完成数 · 版本号 · 回执补账)；内部队列与未来带宽真值仅属物理仿真器与 Oracle 对照组——信息优势须单列，不得混入动作收益

总结：Case B = Case A 的四目标骨架 + 两层新决策 (选路 p、带宽 θ) + 向量化的存储约束与写回耦合；复杂性继承 (页③归约全部保留)、外部性增强 (动作价值不可分解)、可解性依赖有限空间证书 (E-S/E-SP/E-SPB) 与含写回的联合重放增量——这四点构成本文问题定义与后续实验可证可比的基线